阶段三修订报告

一、修订范围与数据边界

1）情感分布与核心主题：本次新增按 top_category 的细分验证，重点覆盖样本量足够的四个类目：Electronics、Home&Kitchen、Computers&Accessories 和 OfficeProducts。

2）推荐效果：ratings_Electronics 数据集本身只包含 Electronics 交互数据，因此无法做跨品类推荐效果比较。为回应模型有效性问题，本次改为补充模型稀疏性诊断、不同活跃度用户层级表现，以及与经典协同过滤基线的效果对比。

二、分品类情感分布与一致性验证

方法上仍使用 TextBlob 计算产品级聚合评论的 polarity，并与星级标签做一致性比对。为避免极小类目带来噪声，下表仅展示产品数不少于 30 的类目。

表 1 主要类目的情感分布与一致性验证

类目	产品数	平均评分	平均极性	正向占比	文本-评分不一致率
Electronics	490	4.08	0.325	98.8%	25.9%
Home&Kitchen	448	4.04	0.349	97.1%	32.6%
Computers&Accessories	375	4.15	0.359	99.2%	16.8%
OfficeProducts	31	4.31	0.423	96.8%	3.2%

- Home&Kitchen 的文本-评分不一致率最高，为 32.6%，高于 Electronics 的 25.9% 和 Computers&Accessories 的 16.8%。这说明通用情感模型在 Home&Kitchen 场景下更容易把混合评价、场景抱怨或局部功能问题判断得过于正向。
- Computers&Accessories 的不一致率相对较低（16.8%），说明该类评论更接近功能评价，模型稳定性更好。
- OfficeProducts 的不一致率最低，但其样本量只有 31 条产品文档，应谨慎解释，不能与前三类目完全等量齐观。

三、分品类核心主题验证

原报告只给出了全样本 LDA。本次对四个主要类目分别运行 3 主题 LDA，并将每个类目占比最高的两类主题合并展示如下。

表 2 主要类目的核心主题摘要

类目	主要主题（前二）	代表词（截取）
Electronics	价格/可用性与基础体验（38.4%）；音频、线缆与外设表现（33.7%）	watch, nice, remote, money, working, good product / sound, bass, cable, like, sound quality, battery
Home&Kitchen	易用性、品质与性价比（62.3%）；安装、出水/加热与基础使用（24.6%）	easy, quality, easy use, product good, money, price / water, coffee, installation, easy, time, hot
Computers&Accessories	充电线缆与快充体验（45.1%）；鼠标/笔记本/外设使用体验（41.3%）	cable, charging, fast, good product, fast charging, nice / mouse, use, price, nice, good product, laptop
OfficeProducts	纸张/笔记本与基础质量（51.6%）；书写、擦除与日常使用（29.0%）	quality, pages, paper, money, notebook, great / pen, ink, best, use, product good, erase

- Home&Kitchen 更集中在安装、出水/加热、风扇/噪音、清洁和房间使用场景，这类文本天然包含更多场景化表达，也更容易出现“总体满意但局部抱怨”的混合语义。
- Electronics 主要围绕音频/外设表现、屏幕/电池、手机/电视等设备特征展开，评论更偏参数与体验并存。
- Computers&Accessories 的主题明显偏向线缆、快充、USB、路由/WiFi 连接速度，更功能化、术语化。

四、推荐模型低 Precision@10 的原因定位

针对“Precision@10 仅约 1%”的问题，本次补做了稀疏性与样本规模诊断，重点结果如下。

表 3 推荐模型诊断摘要

诊断指标	数值	解释
评分原始行数	2,000,000	原型阶段仅读取前 2,000,000 行评分数据
过滤后正向交互数	111,019	用户至少 5 个正反馈、商品支持度条件过滤后
建模用户数	14,936	用于建模的用户数
建模商品数	11,221	用于建模的商品数
交互矩阵密度	0.066%	用户-商品矩阵密度，越低说明越稀疏

用户平均正向商品数	7.43	过滤后用户平均正向商品数
评估用户数	4,143	总正向商品数 >= 8 的评估用户数
评估用户平均训练商品数	9.58	评估用户平均训练商品数
评估用户平均测试商品数	2.55	评估用户平均留出测试商品数

- 数据稀疏性是第一原因。过滤后用户-商品矩阵密度只有 0.066%，候选重叠很弱。
- 样本量与切分方式是第二原因。原型阶段只用前 2,000,000 行评分；进入评估集的用户平均训练商品数仅 9.58 个，平均测试商品数只有 2.55 个，Top 10 指标天然偏低。
- 模型表达能力有限是第三原因。当前模型只使用二值化的正向交互（rating >= 4），没有利用评分强度、时间顺序、文本与商品属性。

五、协同过滤对比

为回应“是否只对比了热门基线”的问题，本次新增两个经典协同过滤基线：item-based CF（基于共现余弦）和 user-based CF（二值余弦近邻）。四个模型在同一评估集上的结果如下。

表 4 推荐模型对比结果

模型	评估用户数	Precision@10	Recall@10	HitRate@10
User-based CF (binary cosine neighbors)	4143	1.14%	4.51%	10.40%
Association-based recommender	4143	1.06%	4.10%	9.68%
Popularity baseline	4143	0.85%	3.48%	8.16%
Item-based CF (cosine on co-occurrence)	4143	0.56%	2.06%	4.97%

- 新增的 user-based CF 表现最好，Precision@10 为 1.14%，Recall@10 为 4.51%，HitRate@10 为 10.40%，略高于原关联规则模型。
- 原有的 association-based recommender 仍优于热门商品基线，说明简单共现已经具备一定个性化能力。
- item-based CF（基于共现余弦）反而低于热门基线，说明在当前稀疏样本下，纯物品相似度容易因共现证据不足而失效。

六、不同活跃层级结果

表 5 最优模型（User-based CF）在不同活跃度层级上的表现

用户活跃度分层	用户数	Precision@10	Recall@10	HitRate@10
10-14	1483	1.13%	4.93%	10.38%
15+	747	1.83%	4.13%	14.99%
8-9	1913	0.87%	4.34%	8.63%

可以看到，用户历史越丰富，推荐效果越好：15+ 正向商品用户的 Precision@10 达到 1.83%，明显高于 8-9 商品用户的 0.87%。这进一步说明当前指标偏低并不等于模型完全无效，而是对低交互、低重叠用户更难做准。

七、结论

1）原报告确实偏向全样本混合视角，本次已补充分品类验证。结果显示，Home&Kitchen 的文本-评分不一致率最高，是最需要谨慎解释 TextBlob 结果的类目；不同类目的核心主题也存在明显差异，不能用单一主题结论概括全部品类。

2）推荐模型的低 Precision@10 主要来自数据稀疏性、样本规模有限和模型表达能力偏弱三者叠加，而不是单一模型失效。

3）在经典基线对比中，新增的 user-based CF 略优于原关联规则模型，说明只与热门榜对比确实不够充分，这一点已在修订中补齐。

4）跨品类推荐效果比较仍无法完成，因为当前交互数据源仅覆盖 Electronics。该限制需要在最终汇报中明确说明，不能把 Electronics 的推荐结果外推为全平台多品类结论。